让智能体记忆表现有据可查

项目目标

在明确任务与运行条件下，用可复核证据评估记忆表现，定位失败并说明观测边界。核心工具使用 Python 标准库，可离线运行，无需 GPU 或模型密钥。

完整流程

版本化案例 → 原生 OpenClaw / Hermes → 新会话与独立工作区 → 回答、可见记忆、工具、真实文件 → 确定性评分 → HTML 六维图与逐事件证据 → 独立重放。

六维与正式数据

长期保持、记忆调用、动态更新、相近区分、边界识别、任务复用。36 标准案例是六模板的事实变体；独立挑战集 12 案例。DeepSeek Flash 同模型，两款各三轮，openKylin 2.0 SP1 用户空间 / WSL 2。

历史标准集成绩

openclaw：已观测分 93.06%，覆盖率 86.34%；hermes：已观测分 91.18%，覆盖率 85.03%

历史挑战集订正成绩

openclaw：已观测分 79.63%，覆盖率 97.22%；hermes：已观测分 95.83%，覆盖率 100.00%。“松柏 / 松柏项目”合法别名订正公开，原分数和证据保留；不同数据集不混算排名。

最有价值的失败案例

Hermes 的 #28 → #30 → #34 → #35：相近但不同的项目被当作同一条信息的修订。原项目回答错误，归档项目回答正确，可见记忆支持作用域混淆线索。

交付、复核与诚实的测量边界

新增压力题

30 条首期开发历史及四题族四档共 160 条离线场景。程序化状态 Oracle、充分原始证据对照、反事实检查、集合约束与反馈任务；离线规模不等于真实全量成绩。

Luna 校题结论

8 条短历史、两款原生 Agent 各一轮，memory 与 reader_only 分开，共 32 案例。memory 两款各正确 1/8，Hermes 含 1 个执行错误；读者共正确 11/16，未达预设 14/16。集合题读者失败，不能把全部失分归为记忆。新增题保留探索定位，不宣称难度充分或稳定排名。

评分与底座检查

30 条固定契约样例、4 组指标对照及新增负例检查；没有第三方独立人审。openKylin 无凭据、隔离网络复核原件、拒绝篡改；参考适配器验证跨进程保留和工作区隔离，不代表真实 Agent TTL 或全局删除。

可获取的交付

源码、JSONL 数据、原生适配器、wheel、.deb、离线导览、技术报告、两页摘要、证据与源码快照、录制手册 / 旁白 / 字幕。最终 MP4 由提交者录制；具体安装验收以精确包散列和日志为准。

接收者三步

打开 START_HERE.md；查看正式报告并下钻事件；执行 python3 verify-delivery.py。核心 demo 与证据复核不调用模型。原生新实验需安装运行时并配置自己的模型认证。

维护与边界

github.com/JacobDaiHit/kylin-memory-bench，GitHub Issues 为公开维护入口。合成数据、模拟时间、部分存储可见性和 WSL 范围明确披露。散列链不是第三方可信执行证明；录制就绪不等于主办方已收件。