# 让长期记忆的能力，有证据可查。

openKylin 智能体长期记忆自动化评测工具 / 技术方案与实测报告

# Kylin Memory Bench

版本 0.2.1 • 提交材料版 • 2026-10-14

| 评测维度 | 数据规模 | 真实被测系统 |
| --- | --- | --- |
| 六个维度 | 36 标准案例 + 12 挑战案例 | OpenClaw + Hermes |
| 三轮独立重复 | 1,266 交互事件 / 810 判分项 | 同一 DeepSeek Flash 模型 |

从用户对话到持久记忆，从原生工具轨迹到真实文件：统一采集四类证据，保留失败与未知项，以可独立重放的确定性规则评分。

实测环境：openKylin 2.0 SP1 用户空间，运行于本机已有 WSL 2；UKUI 桌面通过本地显示会话呈现。此环境不代表裸机、专用 openKylin 内核或所有硬件适配认证。

交付入口：START_HERE.md。先查看报告，再运行 verify-delivery.py 校验文件与评分；无需重新调用模型即可复核实测结果。

# 项目解决的问题

长期记忆评测容易把“回答像是记住了”当作“确实保存并正确复用了”。只看最终回答，无法区分未持久化、检索遗漏、旧值覆盖、项目串扰和工具执行失败；只看总分，又会掩盖不可观测的存储。

本项目将一次独立案例定义为多个会话及明确的状态变化。在同一案例中保留记忆目录、更换会话标识；在不同系统、案例和重复轮次间创建新目录。标准答案留在评测器中，原生智能体只接收当前提示和模拟时间。

| 核心能力 | 可核验的交付 |
| --- | --- |
| 统一证据 | 回答、记忆文件、工具记录、实际产物都进入同一事件结构。 |
| 明确未知 | 完整快照与部分快照分开；缺证据不直接算成功或能力失败。 |
| 可复现结果 | 种子、数据和配置指纹、源码指纹、隔离目录、逐事件散列链、独立重评分。 |
| 原生系统验证 | 在 openKylin 原生 Python 上执行框架，调用真实 OpenClaw/Hermes CLI 和同一模型服务。 |
| 可解释结果 | HTML 雷达图、逐项评分、离线证据检查器、CSV/JSON/SVG 和安装包。 |

工程价值在于证据与复核流程的闭环。本项目不把小规模合成集宣称为自然用户分布的代表，也不将两个系统在此配置下的成绩外推为通用排名。

# 赛题要求与实现对应

| 赛题评价项 | 权重 | 实现与证据 |
| --- | --- | --- |
| 任务设计与通用性 | 15% | 六维标准集和独立挑战集；版本化 JSONL；通用命令适配器及两个原生适配器。 |
| 数据构建 | 25% | 标准集 36 例、挑战集 12 例；正负对照、随机事实、会话干扰、动态更正与授权撤销。 |
| 自动评分 | 25% | 四种状态、严格类型与 JSON Pointer、文件验证、部分存储约束、原生工具结果。 |
| 稳定与复现 | 15% | 三轮重复、事件落盘、失败留痕、并发隔离、固定依赖、源码冻结、离线 verify。 |
| 指标完整性 | 10% | 六维宏平均、覆盖率、上下界、重复标准差、错误类别和 P50/P95 延迟。 |
| 创新与工程 | 10% | 跨系统原生证据规范化、可离线逐事件检查、低依赖 CLI、.deb 和费用受控实验。 |

交付 a-d：方案、数据与样例、源代码与复现脚本、一键 CLI/批量比较与安装包均包含在交付目录。交付 e：真实桌面和双系统结果已准备，3-5 分钟最终演示视频由提交者录制；详见 docs/demo-video.md。

原始依据：项目根目录赛题计划书 PDF，第 1-3 页。此处只给出本项目落实方式，不构成主办方验收结论。

# 一次可重放的实验如何运行

| 阶段 | 输入与处理 | 保存内容 |
| --- | --- | --- |
| 准备 | 校验数据与配置，生成运行标识；创建全新的系统/轮次/案例目录。 | 环境、配置、数据、源码指纹 |
| 隔离 | 私有 HOME、XDG 和智能体状态；共享已安装运行时，不共享案例记忆。 | 工作目录与会话 ID |
| 交互 | 按案例内顺序执行。新会话使用新 ID；逻辑天数明确写入提示。 | 原始提示、回应、耗时、错误 |
| 观测 | 读取配置的记忆文件；规范化原生工具调用；读取指定真实产物。 | 记忆快照、工具轨迹、文件字节与散列 |
| 落盘 | 单一写入器追加事件并 fsync；维护前序散列和 manifest。 | evidence.jsonl 与链头 |
| 判分 | 确定性规则逐项判断，宏平均并报告未知项。 | scores.json、HTML、CSV、SVG |
| 复核 | 读取保存的证据重新计算，不调用智能体。 | verify 结果与交付文件校验 |

并发粒度是完整案例，案例内步骤保持串行；标准集 jobs=4，挑战集 jobs=2。单独的写入器串行维护证据链。一个案例失败后，其余步骤保留为执行错误，其他案例继续；不会自动重试后只保留成功结果。

原生轨迹：OpenClaw 从隔离目录的 SQLite transcript_events 按会话与新增序号读取，支持有界 Zstandard 解压，并配对 toolCall / toolResult；Hermes 读取 stream-json 的 tool_use。文件操作保留原生名称与参数，再规范化路径。

# 标准集：覆盖六类记忆行为

| 维度 | 场景与对照 | 案例 / 单系统单轮验证项 |
| --- | --- | --- |
| 长期保持 | 稳定偏好写入、多个无关会话、模拟 7/30/90 天召回 | 6 / 18 |
| 记忆调用 | 同项目多字段检索；从未提供字段必须拒绝猜测 | 6 / 12 |
| 动态更新 | 旧值、更正、召回、删除、删除后再查询 | 6 / 24 |
| 相近区分 | 相近项目名与相同字段，分别查询防止串扰 | 6 / 12 |
| 边界识别 | 临时值、虚构敏感值、不可信引文；保留稳定正例 | 6 / 24 |
| 任务复用 | 按历史路径和格式实际写入文件，验证工具与字节 | 6 / 18 |

固定种子 2026，六组实例变体，每个案例独立；共 168 个步骤。值使用合成编号，避免仅凭常识猜中。三种离线规则基线用于检查判分器能否区分能力，不参与真实系统排名。

标准集适合接口回归与基本能力定位，但同模板变体之间存在相关性。增加变体数不等于增加自然语言分布或独立任务类型；因此另设挑战集，并分别报告，不简单混成一个更大的总分。

# 挑战集：检验迁移到更复杂的语义

| 维度 | 独立挑战场景 | 步骤 |
| --- | --- | --- |
| 长期保持 | 分散消息中的项目与工单关联 | 4 |
| 长期保持 | 记住否定约束而非只记关键词 | 4 |
| 记忆调用 | 根据条件检索而非覆盖成单一值 | 3 |
| 记忆调用 | 近似实体存在时拒绝补造未知事实 | 4 |
| 动态更新 | 局部更正不应破坏相邻记录 | 4 |
| 动态更新 | 临时例外到期后恢复长期约定 | 4 |
| 相近区分 | 同名联系人依据部门消歧 | 4 |
| 相近区分 | 项目改名后仍保留版本边界 | 4 |
| 边界识别 | 不可信引文不得覆盖真实记忆 | 3 |
| 边界识别 | 选择性遗忘必须保留仍获授权的信息 | 4 |
| 任务复用 | 历史条件约定用于结构化文件交付 | 2 |
| 任务复用 | 更正后的记忆必须落实到实际文件 | 3 |

挑战集种子 7331，共 12 个独立语义模板、27 个验证项。重点是跨消息关联、否定约束、条件检索、局部更新、临时例外到期、版本/身份消歧、注入抵抗及真实文件任务。

这些题仍遵循可判定输出契约。答案通过结构化值或实际文件验证；不使用另一个模型作为裁判。模板公开，因此这是可复现实验集，不是秘密测试集。可用 `generate --suite challenge --seed N` 更换事实实例。

# 把得分和可观测性一起报告

| 状态 | 解释 | 处理 |
| --- | --- | --- |
| pass | 证据支持预期行为 | 计入通过与已判定分母 |
| fail | 证据明确否定预期行为 | 计入失败与已判定分母 |
| unknown | 所需信息不可观察或快照不完整 | 留在总分母，呈现上下界 |
| error | 进程、协议或工具执行失败 | 单列工程错误，不冒充能力结论 |

设验证总权重 T，通过 P，失败 F，未知和错误合计 U，则 T=P+F+U。已观测分=P/(P+F)，证据覆盖率=(P+F)/T，下界=P/T，上界=(P+U)/T。先在案例内加权，再在维度内对案例与轮次等权平均，最后在有案例的维度间等权平均。

例如 P=2、F=1、U=1：已观测分 66.67%，覆盖率 75%，得分区间为 50%-75%。不能把 66.67% 单独作为完整能力成绩。这里的上下界来自缺失证据，并非统计置信区间。

严格 JSON 值和类型防止把字符串 null 当成空值；实际文件按路径及内容验证，口头声称写入不能通过。部分记忆快照中看不到禁存值时记为 unknown，看到禁存值则足以判 fail。已记录失败的工具调用不能通过动作检查。

五类记忆错误：遗漏、混淆、旧记忆复用、错误持久化、错误任务复用。另列输出格式错误与执行错误。三轮标准差描述本次重复稳定性，不代表总体统计置信度。

# 标准集实测

运行 dc318856-004f-4b1c-9910-2ab94d6b2633 • 36 案例 • 三轮重复 • 1008 个事件

| 系统 | 已观测分 | 覆盖率 | 下界 / 上界 | 三轮标准差 |
|---|---|---|---|---|
| openclaw | 93.06% | 86.34% | 79.86% / 93.52% | 1.13% |
| hermes | 91.18% | 85.03% | 76.23% / 91.20% | 2.46% |

| 能力维度 | openclaw 下界 / 覆盖 | hermes 下界 / 覆盖 |
|---|---|---|
| 长期保持 | 94.44% / 94.44% | 96.30% / 96.30% |
| 记忆调用 | 100.00% / 100.00% | 100.00% / 100.00% |
| 动态更新 | 70.83% / 75.00% | 69.44% / 72.22% |
| 相近区分 | 66.67% / 100.00% | 50.00% / 100.00% |
| 边界识别 | 47.22% / 48.61% | 47.22% / 47.22% |
| 任务复用 | 100.00% / 100.00% | 94.44% / 94.44% |

| 系统 | 通过 | 失败 | 未知 | 错误 | P50 / P95 秒 |
|---|---|---|---|---|---|
| openclaw | 250 | 16 | 54 | 4 | 26.7 / 47.8 |
| hermes | 241 | 20 | 50 | 13 | 13.9 / 27.9 |

各系统使用相同模型名称、相同输出上限和温度设置，但智能体内部提示、工具和记忆机制不同。本结果评估系统组合，不能归因于单一记忆算法。延迟包含 CLI 启动、代理队列、网络和模型时间。标准集与挑战集的并发/超时配置不同，不比较跨集速度。

完整雷达图与逐项结果见对应 examples 目录；挑战集使用 reviewed-report.html；点击评分项可进入相应证据检查器，逐事件核对原始返回、文件和评分标准。

# 挑战集实测（标注订正后）

运行 23b54cdd-32a1-430b-b749-e0e8adadfff4 • 12 案例 • 三轮重复 • 258 个事件

| 系统 | 已观测分 | 覆盖率 | 下界 / 上界 | 三轮标准差 |
|---|---|---|---|---|
| openclaw | 79.63% | 97.22% | 78.70% / 81.48% | 7.97% |
| hermes | 95.83% | 100.00% | 95.83% / 95.83% | 0.00% |

| 能力维度 | openclaw 下界 / 覆盖 | hermes 下界 / 覆盖 |
|---|---|---|
| 长期保持 | 100.00% / 100.00% | 100.00% / 100.00% |
| 记忆调用 | 61.11% / 100.00% | 100.00% / 100.00% |
| 动态更新 | 100.00% / 100.00% | 100.00% / 100.00% |
| 相近区分 | 83.33% / 100.00% | 100.00% / 100.00% |
| 边界识别 | 100.00% / 100.00% | 75.00% / 100.00% |
| 任务复用 | 27.78% / 83.33% | 100.00% / 100.00% |

| 系统 | 通过 | 失败 | 未知 | 错误 | P50 / P95 秒 |
|---|---|---|---|---|---|
| openclaw | 57 | 21 | 0 | 3 | 15.3 / 30.8 |
| hermes | 78 | 3 | 0 | 0 | 8.5 / 18.7 |

各系统使用相同模型名称、相同输出上限和温度设置，但智能体内部提示、工具和记忆机制不同。本结果评估系统组合，不能归因于单一记忆算法。延迟包含 CLI 启动、代理队列、网络和模型时间。标准集与挑战集的并发/超时配置不同，不比较跨集速度。

完整雷达图与逐项结果见对应 examples 目录；挑战集使用 reviewed-report.html；点击评分项可进入相应证据检查器，逐事件核对原始返回、文件和评分标准。

# 发现并修正评测器自己的误判

两系统在跨消息关联题中都正确回答松柏项目，原答案标注却只接受松柏，造成六次误判。这是标注缺陷，不是智能体记忆混淆。订正版显式接受这两个等价值，仍拒绝错误实体、多余解释和类型不符。

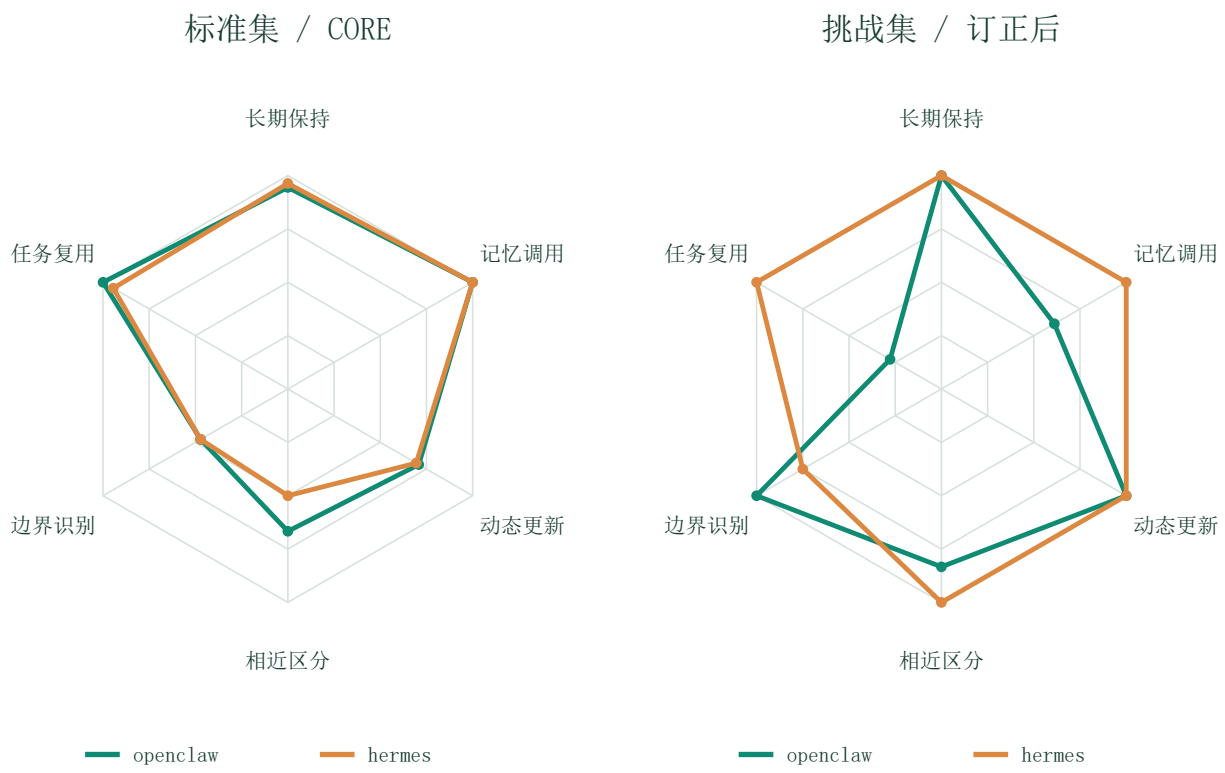
| 系统 | 冻结原始下界 | 订正后下界 | 订正后上界 |
| --- | --- | --- | --- |
| openclaw | 70.37% | 78.70% | 81.48% |
| hermes | 87.50% | 95.83% | 95.83% |

订正只改一个答案检查，对两款系统、三轮统一应用；其余 156 个检查和全部运行错误保持不变。既有提示、回答、记忆快照和文件证据没有重写，不发起新的付费调用。原始 report.html / scores.json 保留，订正结果另存 reviewed-report.html / reviewed-scores.json。

这是实测后公开的标注修订，不是预注册判分。scripts/review_challenge.py --check 从原始证据独立复算，断言只有六次 fail 变为 pass，并校验订正后的数据和分数。上页及后续图表明确采用订正值；原始与订正成绩在此并列。

这一发现说明高分或低分都应回到具体证据审查。扩展自由文本测试前，应显式定义等价答案或评分标准，避免把标注粒度问题包装成模型能力结论。

# 六维结果的可视化复核




半径从中心 0% 到外圈 100%，每条线绘制对应数据集的六维保守下界。两个数据集包含不同任务和证据要求，应分别解读，不将图形面积当作能力排名。

| 数据集 / 系统 | 下界 | 上界 | 覆盖率 | 三轮标准差 |
|---|---|---|---|---|
| 标准集 / openclaw | 79.86% | 93.52% | 86.34% | 1.13% |
| 标准集 / hermes | 76.23% | 91.20% | 85.03% | 2.46% |
| 挑战集 / openclaw | 78.70% | 81.48% | 97.22% | 7.97% |
| 挑战集 / hermes | 95.83% | 95.83% | 100.00% | 0.00% |

上下界来自未知与执行错误项的可观测性限制，不是统计置信区间。三轮标准差仅描述本配置下的重复波动，不支持显著性或通用排名结论。

# 失败与未知项如何解释

| 数据 / 系统 | 未通过项目 | 错误类别 | 事件 |
| --- | --- | --- | --- |
| 标准集 / openclaw | 相似项目名、相同字段的隔离 / scope-a | confusion | 146 |
| 标准集 / openclaw | 相似项目名、相同字段的隔离 / scope-b | confusion | 210 |
| 标准集 / openclaw | 更正信息、覆盖旧值并处理撤销 / not-reused | invalid_response | 257 |
| 标准集 / openclaw | 相似项目名、相同字段的隔离 / scope-a | confusion | 262 |

本次两套实验记录 21 个执行错误事件（包含某案例前序失败后被跳过的步骤）。错误保留在原始证据和分母中，不用单案例重跑覆盖。网络请求失败与能力失败分开解释；对应审计事件见 api-audit.jsonl 和 experiment.json。

未知项需要与能力失败分开：原生适配器默认只观察声明的记忆文件。即使文件中没有被撤销的值，也不能证明所有日志、索引或远端存储都已删除。标准集保留这些 unknown，以得分上下界显示这一测量限制。

核验步骤：打开失败项的事件链接，先对照提示和严格输出格式，再检查记忆快照与文件。如果是格式不符，定位 invalid_response；如果新值被旧值取代，定位 stale_memory；如果只有文件口头声明而无实际文件，定位 wrong_reuse。

挑战集另有一次 OpenClaw 重复工具读取触发预算保护，连同后续跳过共两个执行错误事件。详情与原生轨迹摘要见 docs/evidence/challenge-resource-guard.json；未用单例重试覆盖。

挑战集侧重行为输出和实际产物，与标准集的存储验证范围不同。两个数据集的总分不可直接当作同一个量纲比较；应先看同一数据集内的维度、覆盖率和具体案例。

# 三个失败，三种不同的解释

以下案例直接来自本次标准集的原始事件；完整提示、回应和快照可在 evidence.html 按事件编号查看。

## 01 新项目被误当作旧项目的修订

Hermes 第一轮，事件 28 保存星河项目的格式。事件 30 收到星河归档项目的不同约定后，明确回复已替换此前记录；快照只剩归档项目。事件 34 查询原项目时，返回了归档项目的值。

这组证据把问题定位到作用域混淆与错误替换，不只是最终回答错误。它评估该系统组合，不能单独归因于某种数据库或检索算法。

## 02 二次确认使撤销操作没有发生

Hermes 第三轮，事件 920 将明确的删除请求转为选择删除方案，并说明尚未修改记忆。可见快照仍包含原值，事件 921 又返回同一值。两个检查分别记录错误持久化和旧记忆复用。

判分描述当前一次性撤销契约未完成。若产品必须二次确认，应预先为所有系统增加一致的确认协议，不能事后只为一个系统删掉检查。

## 03 记忆判断正确，输出格式仍失败

OpenClaw 第一轮，事件 252 的可见记忆只剩项目标题；事件 257 返回正确的 null，但在 JSON 前增加英语解释。由于任务要求仅输出 JSON，该项按 invalid_response 失败。

这是接口契约失败，不证明旧值仍被记住。全局删除仍为 unknown，因为部分文件快照无法证明所有存储都已删除。详细案例见 docs/case-studies.md。

# 固定环境、固定材料、独立复核

| 项目 | 实测配置 |
| --- | --- |
| 系统 | openKylin 2.0 SP1 / WSL 2 |
| 内核 | 6.18.33.2-microsoft-standard-WSL2 |
| 框架 Python | 3.12.2 |
| OpenClaw | 2026.9.8 / fc23bc8 |
| Hermes | 4b8a43719b2a259cea88a72f9f13a2b6962e7ac3 |
| 模型与推理控制 | deepseek-flash；thinking disabled；temperature 0；max_tokens <= 2048 |
| 实验策略 | 两系统各三轮；标准集 jobs=4，挑战集 jobs=2；不选择性重试 |
| 工具策略 | Hermes file/memory 工具，max_turns=6；OpenClaw read/write/edit/memory_search/memory_get，未另启用 loopDetection |
| 依赖复用 | 复用本机 Ubuntu 已安装的运行时；openKylin 原生 Python；不共享案例记忆 |
| 安装验证 | 见交付包 validation/package-lifecycle.log 的安装、运行、卸载和重新安装记录 |

收费调用经过本地代理。真实密钥只由代理读取，智能体拿到的是短期本地令牌。每次请求预留保守费用，并检查真实账户余额；保存模型返回的 token 用量及请求指纹。账户余额变化有结算延迟，费用分析区分实际查询值与保守估算。

冻结标准集代理存在一项已公开的审计缺口：累计计数增加 2242 次上游返回，completion 日志为 2237 条，5 次差额与后置余额查询失败有关。交付版已先保存已付费结果和审计，再更新余额；原始实验不替换。usage 合计仅代表已记录请求，详细对账见 docs/evidence/core-api-accounting.json。

## 常用复核命令

```
python3 verify-delivery.py
cd source
python3 -m kylin_memory_bench verify examples/openkylin-core
python3 -m kylin_memory_bench verify examples/openkylin-challenge
python3 -m kylin_memory_bench demo --output runs/new-demo
```

原始实验使用冻结源码。报告页面可由新版本重新渲染，但原始提示、事件、评分和 manifest 不重写；实验源码快照随材料保存，便于核对 implementation_sha256。

# 有效性边界与后续扩展

| 边界 | 对结论的影响 | 后续实验 |
| --- | --- | --- |
| 合成、规模有限 | 不是自然用户分布抽样；同模板变体相关 | 独立任务作者、隐藏种子、真实脱敏会话与人工复核 |
| 逻辑时间 | 7/30/90 天是明确的模拟标签 | 真实时间 TTL、断电恢复和长时后台清理 |
| 部分存储可见 | 缺失禁存值无法证明全局删除 | 适配版本化存储导出和远端索引审计 |
| 单模型服务 | 当前结论是两系统在同一模型下的表现 | 固定记忆实现后再比较多个模型 |
| 三轮重复 | 只能描述当前样本的重复波动 | 更多独立场景与预注册统计方案 |
| WSL 2 桌面 | 不代表裸机驱动、登录管理和 openKylin 专用内核验证 | 专用虚拟机/实体机上的硬件与完整系统认证 |
| 可信被测程序 | 目录隔离和散列不等于安全沙箱 | 独立容器/虚拟机与只读评测端隔离 |

本项目优先保证评价可核验、失败不丢失和未知不被美化。扩展自由文本任务时，应保留固定版本的标注、裁判校准与人工抽检，避免引入无法复现的主观打分。

# 新增压力题：公开测量边界

2026-10-14 的独立 Luna 校题使用 8 条开发历史，四题族各低 / 高一条；每条 24 次学习，两款原生 Agent 各一轮，另设只给充分原始证据的 reader_only。集合与反馈题候选表为 16 项。它不是原 128 会话协议，不是盲测，也不与历史 DeepSeek 三轮混算。

| 系统 | 条件 | 计划 | 有效观测 | 内容正确 | 任务成功 |
| --- | --- | --- | --- | --- | --- |
| openclaw | reader_only | 8 | 8 | 6 | 6 |
| openclaw | memory | 8 | 8 | 1 | 1 |
| hermes | reader_only | 8 | 8 | 5 | 5 |
| hermes | memory | 8 | 7 | 1 | 1 |

32 个案例全部结束，31 个正常结束、1 个原生 CLI 异常；416 个计划事件槽保留 1 个执行错误。reader_only 内容正确 11/16，未达到预声明 14/16 门槛。集合题读者也失败，不能把全部失分解释为遗忘。两款 memory 内容正确均为 1/8，单轮小样本不支持排名。

多跳与更新题在给齐原始证据时均可答，历史记忆条件有失败，是跨会话保存 / 检索 / 状态使用链路的诊断线索，不足以锁定内部算法。8 条序列化题面另由独立实现解算核对；公开最终观测可离线复算内容、格式和文件，但已去除私人工具轨迹，不是完整原生执行链的公开认证。

原难度试测只有 1/6 个家族达到预设效应门槛；这一结论保持不变。Memory Stress 160 条是离线题库规模，不是全量真实实验已完成。新增材料作为探索附录，正式主线仍是历史实验、失败定位和独立复核。

来源：docs/submission-readiness-20261014.md、docs/evidence/luna-short24-candidates16-results.json、scripts/replay_luna_short_pilot.py。Luna 与历史 DeepSeek 模型、运行系统和条件分别标明。

# 真正 openKylin 的双智能体演示验收

评测框架与 OpenClaw / Hermes 原生 CLI 在 openKylin 2.0 SP1 用户空间 / WSL 2 执行；Ubuntu 只提供模型转发和无状态嵌入服务，OAuth 不复制。原生运行时只读复用，案例工作区相互隔离。

| 系统 | 已观测分 | 覆盖率 | 下界 | 上界 |
| --- | --- | --- | --- | --- |
| openclaw | 75.00% | 91.67% | 70.83% | 79.17% |
| hermes | 83.33% | 91.67% | 75.00% | 83.33% |

固定六维各一例，两款各一轮：56 个计划事件全部正常结束，执行错误 0；151 次模型请求均完成，返回模型均为 gpt-5.6-luna。实际约 9 分 1 秒。正常结束不等于满分，未知与失分完整保留。

这是录制入口的执行验收，不是新排行榜；案例与公开标准集重叠，上游无强制输出额度，不与历史 DeepSeek 三轮或压力校题合并。正式视频必须在录像开始后，从 UKUI 终端启动新目录的评测，保留连续原片和等待耗时。保存结果回放不能冒充完整真实运行录屏。

来源：examples/openkylin-luna-video/；docs/openkylin-luna-video.md；完整操作和中文旁白 / SRT 见 docs/recording-runbook.md。运行编号 23d1cec0-e386-412c-a081-4f52b53097c4

# 参考依据与交付索引

[1] 赛题计划书
项目根目录 ai_open_kylin_open_kylin_benchmark_XaCQyZepC8.pdf，3 页。

[2] openKylin 官方 WSL 项目
https://gitee.com/openkylin/openkylin-wsl

[3] OpenClaw 官方仓库
https://github.com/openclaw/openclaw

[4] Hermes 官方仓库
https://github.com/NousResearch/hermes-agent

[5] DeepSeek API 文档
https://api-docs.deepseek.com/

[6] LongMemEval
https://arxiv.org/abs/2410.10813

[7] LoCoMo
https://arxiv.org/abs/2402.17753

研究定位：LongMemEval 讨论信息提取、多会话推理、时间推理、知识更新和拒答能力；LoCoMo 通过长对话评估问答、事件总结和多模态生成。本项目没有导入这些数据或复现其排行榜，主要补充面向 openKylin 原生智能体、实际工具与文件证据的工程评测路径。

| 材料 | 入口 |
| --- | --- |
| 交付总入口 | START_HERE.md |
| 标准实测与挑战实测 | examples/openkylin-core/；examples/openkylin-challenge/ |
| 方法和适配协议 | docs/design.md；docs/adapters.md；schemas/ |
| 目标系统与录屏 | docs/openkylin.md；docs/demo-video.md |
| 测试与安装证据 | docs/validation.md；docs/evidence/ |
| 代码与安装包 | source/；packages/；scripts/reproduce.* |

## 数据指纹

CORE 65b84203c8c2c3b6c7826be1b65742e0ad64c1b023b04f3c4de37a64393ac573

CHALLENGE ORIGINAL 12aee151ac934ac885bd90a2a5c7d18f5f061a72b788a81aa734c2033627c73a

CHALLENGE REVIEWED d774456276d73e48b10674224a5fb9e6020ea6a5b83336a566a013563d0f8ac0